FIAP

IoT

Global Solution

2026

Definição da solução CitizenTech

1. Definição do problema

O AlertaCidadão tem como objetivo combater a falta de informações acessíveis sobre riscos de enchentes em regiões vulneráveis. Durante períodos de chuvas intensas, moradores de áreas próximas a rios, córregos e locais com histórico de alagamentos podem enfrentar situações perigosas sem receber informações suficientes para se preparar.

Muitas vezes, a população percebe o risco somente quando a água já está subindo nas ruas ou invadindo residências, dificultando a proteção de bens materiais, a busca por locais seguros e a tomada de decisões preventivas.

A solução pretende enfrentar esse problema por meio de um sistema inteligente de monitoramento ambiental, utilizando sensores IoT e Inteligência Artificial para acompanhar as condições dos pontos monitorados, identificar possíveis situações de risco e disponibilizar informações acessíveis à população.

Dessa forma, o projeto está relacionado ao tema CitizenTech, pois utiliza a tecnologia para atender a uma necessidade real da sociedade, contribuindo para a segurança, a prevenção e a qualidade de vida dos cidadãos.

2. Identificação do público beneficiado

O público principal do AlertaCidadão será formado por moradores de regiões com histórico de enchentes e alagamentos, especialmente pessoas que vivem próximas a rios, córregos e áreas vulneráveis a chuvas intensas.

Também poderão ser beneficiados agentes comunitários e órgãos municipais, como a Defesa Civil, que poderão utilizar as informações coletadas para acompanhar as condições dos pontos monitorados.

Os moradores serão beneficiados pelo acesso a informações sobre o nível da água, o volume de chuva e possíveis situações de risco, permitindo que acompanhem as condições das regiões monitoradas e tenham acesso a orientações preventivas.

Os agentes comunitários poderão utilizar os dados para compartilhar informações com a população, enquanto os órgãos responsáveis poderão contar com informações adicionais para apoiar o acompanhamento das áreas monitoradas.

O principal benefício será proporcionar à população informações mais acessíveis e oportunas, ajudando as pessoas a se prepararem diante de possíveis enchentes e a tomarem decisões preventivas.

3. Definição da funcionalidade de Inteligência Artificial

A principal funcionalidade de Inteligência Artificial do AlertaCidadão será a identificação de possíveis riscos de enchentes e a geração de alertas explicativos para a população.

Para isso, a solução utilizará duas abordagens de Inteligência Artificial integradas ao sistema.

A primeira será o Machine Learning, responsável por analisar dados ambientais e identificar padrões que possam indicar o aumento do risco de enchentes. Entre as informações analisadas estarão o nível atual da água, a velocidade de elevação desse nível, o volume de chuva registrado e os dados utilizados para representar o histórico das condições monitoradas.

O modelo utilizará essas informações para classificar as condições monitoradas em quatro categorias: NORMAL, ATENCAO, ALERTA e EMERGENCIA.

A segunda abordagem será a IA generativa, responsável por transformar os resultados da análise em mensagens claras e contextualizadas para os moradores.

A IA generativa receberá a classificação produzida pelo Machine Learning e as informações das medições. Com base nesses dados, produzirá uma mensagem explicativa e orientações preventivas adequadas à situação identificada.

Por exemplo, quando o sistema identificar uma classificação de ALERTA ou EMERGENCIA, a IA generativa poderá produzir uma mensagem recomendando que os moradores evitem áreas alagadas, mantenham distância de rios e córregos e acompanhem os comunicados oficiais da Defesa Civil.

Assim, a Inteligência Artificial estará integrada diretamente ao funcionamento da solução, participando da análise dos dados e da comunicação dos riscos, em vez de funcionar apenas como um chatbot independente.

4. Contribuição da Inteligência Artificial para resolver o problema

A Inteligência Artificial contribuirá para resolver o problema ao transformar os dados coletados pelos sensores em informações úteis para a prevenção de enchentes.

Primeiramente, os sensores IoT realizarão o monitoramento das condições ambientais, coletando informações como o nível da água e dados utilizados para representar o volume de chuva. Essas informações serão transmitidas por MQTT e recebidas pelo Node-RED.

Em seguida, os dados serão organizados e armazenados no banco de dados MySQL. O sistema também realizará o processamento das medições, incluindo o cálculo da velocidade de elevação do nível da água.

Os dados preparados serão encaminhados à API de Machine Learning, responsável por analisar as variáveis e produzir uma classificação do risco.

Posteriormente, a classificação e as informações relacionadas serão encaminhadas à API de IA generativa, que produzirá uma explicação em linguagem natural e orientações preventivas.

As informações poderão ser apresentadas no Dashboard do Node-RED, facilitando o acompanhamento das condições monitoradas.

Com essa integração, o AlertaCidadão pretende facilitar o acompanhamento de áreas vulneráveis, melhorar o acesso à informação, auxiliar na identificação de situações de risco e contribuir para que os moradores tenham mais condições de se preparar diante de possíveis enchentes.

A solução não pretende substituir a atuação da Defesa Civil ou os sistemas oficiais de emergência, mas atuar como uma ferramenta complementar de monitoramento e comunicação preventiva.

Implementação da Inteligência Artificial

5. Implementação da IA generativa

O AlertaCidadão utiliza uma API de IA generativa integrada diretamente ao fluxo da aplicação, com o objetivo de transformar os resultados das análises ambientais em alertas claros, contextualizados e compreensíveis para a população.

A implementação foi desenvolvida utilizando Python e FastAPI, com integração à OpenAI API.

A API generativa foi organizada como um serviço independente, executado na porta 8001, permitindo que o Node-RED encaminhe os resultados produzidos pelo modelo de Machine Learning para a geração de mensagens.

O serviço recebe informações estruturadas, incluindo:

- Classificação de risco produzida pelo Machine Learning.
- Probabilidade informada pelo modelo.
- Fatores considerados na classificação.
- Nível da água registrado.
- Volume de chuva registrado.
- Velocidade de elevação do nível da água.
- Identificação do ponto de monitoramento.

- Data e horário da medição.

Com base nessas informações, o modelo generativo deverá produzir uma mensagem preventiva em português, explicando a situação identificada e apresentando orientações adequadas à classificação recebida.

A implementação também estabelece instruções para impedir que o modelo altere a classificação produzida pelo Machine Learning ou invente medições e informações que não foram fornecidas pelo sistema.

Dessa maneira, a IA generativa não será utilizada como um chatbot independente, mas como parte do processo de comunicação e prevenção da aplicação.

Estado da implementação: a API foi desenvolvida, instalada e iniciada corretamente. O endpoint /health confirmou o funcionamento do serviço e a presença da variável de configuração da chave OpenAI. Entretanto, o teste de geração de texto retornou um erro de limite ou cota da OpenAI, relacionado ao uso e faturamento da API. Portanto, a integração está implementada, mas a geração real de mensagens ainda depende da regularização da cota de utilização.

6. Escolha do modelo e forma de execução

Para implementar a IA generativa, foi escolhida a OpenAI API, permitindo que a aplicação envie os dados analisados e receba como resposta os alertas e textos explicativos gerados.

A escolha por uma API permite integrar a funcionalidade ao sistema sem a necessidade de hospedar e executar um modelo generativo localmente.

A comunicação é realizada por meio de requisições HTTP entre o Node-RED e o serviço de IA generativa, desenvolvido com FastAPI.

A implementação utiliza o SDK oficial da OpenAI para Python e a Responses API para realizar as solicitações de geração de texto.

A configuração da integração utiliza as seguintes variáveis de ambiente:

- OPENAI_API_KEY: chave de autenticação da OpenAI API.
- OPENAI_MODEL: identificação do modelo generativo utilizado.

As credenciais são armazenadas em um arquivo .env, que está incluído no .gitignore, evitando que a chave seja disponibilizada no código-fonte público.

O modelo generativo será utilizado exclusivamente para explicar os resultados fornecidos pelo sistema e produzir mensagens informativas.

A classificação do risco permanece sob responsabilidade do modelo de Machine Learning, evitando que a IA generativa determine níveis de risco sem respaldo nos dados.

7. Escolha da técnica de aprofundamento técnico: Machine Learning

A técnica escolhida para o aprofundamento técnico do AlertaCidadão é o Machine Learning (Aprendizado de Máquina).

O Machine Learning é utilizado para analisar os dados ambientais recebidos pelo sistema e identificar padrões que possam indicar o aumento do risco de enchentes.

Para essa finalidade, foi implementado um modelo baseado no algoritmo Random Forest Classifier, pertencente à categoria de métodos de aprendizado supervisionado.

O modelo considera as seguintes variáveis:

- Nível da água registrado.
- Velocidade de elevação do nível da água.
- Volume de chuva registrado.
- Informações utilizadas para representar as condições de monitoramento.

A partir dessas informações, o modelo produz uma classificação entre quatro categorias:

- NORMAL.
- ATENCAO.
- ALERTA.
- EMERGENCIA.

A implementação atual da API de Machine Learning utiliza um conjunto de 6.000 registros sintéticos gerados para fins de demonstração e treinamento inicial do modelo.

O modelo é inicializado junto à API e disponibiliza o endpoint POST /predict, responsável por receber os dados ambientais e retornar a classificação, a probabilidade informada pelo modelo, os fatores identificados e informações sobre o modelo utilizado.

O serviço também disponibiliza o endpoint /health, utilizado para verificar o estado da API e confirmar se o modelo foi carregado corretamente.

É importante destacar que os dados sintéticos permitem demonstrar o funcionamento técnico da integração, mas não representam um treinamento

validado com ocorrências reais de enchentes. Para utilização em condições reais, será necessário obter dados históricos confiáveis, com classificações devidamente identificadas, e realizar uma avaliação do desempenho do modelo.

8. Justificativa técnica da escolha do Machine Learning

A escolha do Machine Learning foi realizada porque o problema de enchentes envolve diferentes variáveis ambientais que podem apresentar alterações ao longo do tempo.

Analisar essas informações de maneira conjunta permite identificar padrões que podem indicar mudanças nas condições de risco de uma determinada região.

O algoritmo Random Forest foi escolhido por permitir combinar diferentes árvores de decisão durante o processo de classificação, considerando relações entre as variáveis utilizadas como entrada.

Essa abordagem é adequada ao AlertaCidadão porque permite utilizar os dados coletados pelos sensores IoT para desenvolver uma análise das condições monitoradas.

Além disso, o modelo pode trabalhar com diferentes variáveis numéricas, como nível da água, volume de chuva e velocidade de elevação, produzindo uma classificação que poderá ser utilizada por outros componentes da aplicação.

Seus resultados também podem ser integrados à IA generativa, que ficará responsável por transformar as classificações em mensagens acessíveis à população.

Portanto, a utilização conjunta de Machine Learning e IA generativa permitirá que o AlertaCidadão não apenas monitore as condições ambientais, mas também classifique os dados e facilite a comunicação de possíveis riscos.

Organização dos Dados e Arquitetura

9. Identificação das fontes de dados utilizadas

O AlertaCidadão utiliza dados provenientes de sensores simulados e informações geradas para demonstrar o funcionamento do modelo de Machine Learning.

As fontes e os dados considerados no desenvolvimento são:

Sensores IoT simulados no Wokwi

Foi desenvolvido um protótipo utilizando ESP32 no ambiente Wokwi, com os seguintes componentes:

- Sensor ultrassônico HC-SR04, utilizado para simular a medição do nível da água.
- Potenciômetro, utilizado para simular a variação do volume de chuva.

O ESP32 realiza a leitura dos componentes e transmite os dados por MQTT, utilizando o broker público HiveMQ.

As mensagens são publicadas no tópico:

enchente/alertacidadao_01/telemetria

O payload enviado contém informações como identificação do ponto de monitoramento, nível da água, chuva e data e horário da medição.

Dados sintéticos para Machine Learning

Para a implementação inicial do modelo de Machine Learning, foi utilizado um conjunto de 6.000 registros sintéticos.

Esses registros foram gerados para permitir o treinamento e a demonstração do funcionamento do Random Forest Classifier, contemplando diferentes condições de monitoramento e as quatro classificações de risco definidas para o projeto.

Esses dados não devem ser considerados registros históricos reais de enchentes nem evidência de desempenho validado em situações reais.

Dados meteorológicos e históricos

Fontes públicas, como o Instituto Nacional de Meteorologia (INMET) e o Centro Nacional de Monitoramento e Alertas de Desastres Naturais (CEMADEN), poderão ser utilizadas em etapas futuras para complementar o monitoramento e obter informações históricas confiáveis.

Entretanto, a integração direta dessas fontes externas ainda não faz parte da implementação atual.

A utilização dessas informações dependerá da disponibilidade dos dados, das condições de acesso e da adequação das informações aos pontos de monitoramento do projeto.

10. Preparação e organização dos dados

Antes de serem utilizados pelo modelo de Machine Learning, os dados passam por um processo de organização e preparação, garantindo que estejam estruturados e adequados para a análise.

No protótipo atual, o Node-RED recebe as mensagens MQTT publicadas pelo ESP32 e executa uma etapa de validação e preparação das informações.

Os principais campos utilizados são:

- Identificação do ponto de monitoramento.
- Data e horário da medição.
- Nível da água registrado.
- Volume de chuva simulado.
- Velocidade de elevação do nível da água.

As atividades de preparação implementadas ou previstas incluem:

Validação: verificar se os valores recebidos possuem a estrutura e os formatos esperados, evitando o processamento de mensagens inválidas.

Tratamento de dados ausentes: identificar informações que não foram recebidas ou estão incompletas, evitando que registros inadequados sejam encaminhados ao processamento.

Remoção de inconsistências: identificar registros duplicados, valores incorretos e possíveis falhas de leitura dos sensores.

Organização temporal: organizar as medições por data e horário para permitir acompanhar a evolução das condições ambientais.

Transformação dos dados: calcular a velocidade de elevação do nível da água utilizando a comparação entre a medição atual e a anterior, considerando o intervalo de tempo entre elas.

Armazenamento: registrar as medições no banco de dados MySQL, permitindo consultar o histórico dos pontos monitorados.

A tabela utilizada para armazenar as medições é denominada leituras_enchente e contém informações como identificação do ponto, nível da água, volume de chuva, velocidade de elevação, data e horário e data de registro.

Para o treinamento e a avaliação de um modelo destinado a aplicações reais, também será necessário utilizar registros históricos confiáveis e classificações devidamente identificadas.

Esses dados deverão ser organizados em conjuntos de treinamento, validação e teste, quando houver volume suficiente de informações.

Essa separação permitirá avaliar o desempenho do modelo com registros que não foram utilizados diretamente durante seu treinamento.

Na implementação atual, o conjunto sintético permite demonstrar o fluxo de classificação, mas ainda não substitui uma base histórica real e validada.

11. Documentação da arquitetura da solução

A arquitetura do AlertaCidadão foi organizada em componentes integrados, responsáveis pela coleta, comunicação, armazenamento, processamento, análise e apresentação das informações.

A solução utiliza ESP32, MQTT, Node-RED, MySQL, uma API de Machine Learning e uma API de IA generativa.

O funcionamento é organizado nas seguintes etapas:

1. Coleta de dados com IoT

O ESP32, executado no ambiente Wokwi, realiza a leitura do sensor ultrassônico e do potenciômetro. Os componentes são utilizados para representar as condições de monitoramento do nível da água e do volume de chuva.

2. Comunicação MQTT

As informações coletadas são enviadas pelo ESP32 utilizando o protocolo MQTT, por meio do broker público HiveMQ.

O Node-RED recebe as mensagens publicadas no tópico enchente/alertacidadao_01/telemetria.

3. Recebimento e preparação dos dados

O Node-RED recebe as informações, valida a estrutura das mensagens e prepara os dados para o processamento.

Também utiliza a medição anterior para calcular a velocidade de elevação do nível da água.

4. Armazenamento

As medições são registradas no banco de dados MySQL, na tabela leituras_enchente, permitindo consultar o histórico e acompanhar as condições dos pontos monitorados.

5. Análise com Machine Learning

O Node-RED encaminha os dados preparados para a API de Machine Learning, desenvolvida com Python e FastAPI e executada na porta 8000.

O modelo Random Forest analisa as variáveis recebidas e produz uma classificação entre NORMAL, ATENCAO, ALERTA e EMERGENCIA.

A resposta também apresenta informações adicionais, como a probabilidade informada pelo modelo e os fatores relacionados à classificação.

6. Integração com IA generativa

O resultado da análise é encaminhado pelo Node-RED para a API de IA generativa, desenvolvida com FastAPI e executada na porta 8001.

Esse serviço utiliza a OpenAI API para produzir uma mensagem explicativa em linguagem natural, com orientações preventivas adequadas à classificação recebida.

7. Disponibilização das informações

O Node-RED apresenta os dados no Dashboard, disponibilizando indicadores de nível da água, volume de chuva, gráficos e informações históricas.

A mensagem explicativa gerada pela IA também poderá ser apresentada no Dashboard após a conclusão da chamada à OpenAI.

8. Acompanhamento

O Dashboard permite acompanhar as condições simuladas dos pontos monitorados, consultar as medições e visualizar a classificação produzida pelo modelo.

As informações têm caráter complementar e devem ser interpretadas considerando os comunicados oficiais dos órgãos responsáveis.

Fluxo resumido da arquitetura:

ESP32 no Wokwi → MQTT / HiveMQ → Node-RED → Validação e preparação dos dados → MySQL → API de Machine Learning → API de IA generativa / OpenAI → Dashboard Node-RED.

12. Integração da Inteligência Artificial à solução CitizenTech

A Inteligência Artificial está integrada diretamente à arquitetura do AlertaCidadão, contribuindo para transformar dados ambientais em informações úteis para a população.

O Machine Learning é responsável por analisar os dados recebidos dos sensores IoT e classificar as condições monitoradas de acordo com o nível de risco.

A IA generativa utiliza os resultados dessa classificação para produzir alertas explicativos, transformando informações técnicas em mensagens mais simples e compreensíveis.

Essa integração é realizada por meio de duas APIs independentes, desenvolvidas em Python com FastAPI.

A primeira API, executada na porta 8000, utiliza o algoritmo Random Forest para classificar os dados ambientais.

A segunda API, executada na porta 8001, integra-se à OpenAI API para gerar as mensagens preventivas a partir dos resultados recebidos.

O Node-RED atua como componente de integração, recebendo os dados MQTT, organizando as medições, armazenando os registros no MySQL e encaminhando as informações para os serviços de Inteligência Artificial.

O Dashboard disponibiliza os dados e os resultados do monitoramento de maneira visual.

Essa arquitetura permite separar as responsabilidades dos componentes, facilitando a manutenção e a evolução da solução.

A utilização dessas tecnologias está diretamente relacionada ao conceito CitizenTech, pois coloca a tecnologia a serviço de uma necessidade real da sociedade: a prevenção de enchentes e a proteção de comunidades vulneráveis.

Ao aproximar o monitoramento ambiental da população, o AlertaCidadão pretende melhorar o acesso à informação, auxiliar na tomada de decisões preventivas e contribuir para comunidades mais preparadas diante de eventos climáticos extremos.

A solução será complementar aos sistemas oficiais de monitoramento e alerta, não substituindo as orientações ou decisões da Defesa Civil e de outros órgãos responsáveis.

Situação atual da implementação

O desenvolvimento técnico do AlertaCidadão já contempla a construção e integração dos principais componentes da arquitetura.

Componente	**Implementação**	**Situação**
ESP32 e sensores no Wokwi	Leitura simulada do nível da água e da chuva	Implementado e testado
Comunicação MQTT	Broker público HiveMQ	Implementado e testado
Node-RED	Recebimento e processamento das mensagens	Implementado e testado
Banco MySQL	Armazenamento das medições	Implementado

Dashboard	Indicadores, gráficos e histórico	Implementado e testado
API Machine Learning	FastAPI com Random Forest	Implementada e iniciada
API IA generativa	FastAPI integrada à OpenAI	Implementada e iniciada
Comunicação com a OpenAI	Requisição real de geração de texto	Pendente de validação por limite/cota da API
Dados históricos reais	Base rotulada para treinamento e avaliação	Pendente
Integração com INMET/CEMADEN	Fontes externas de dados meteorológicos	Planejada

Limitações e considerações técnicas

A implementação atual é um protótipo acadêmico desenvolvido para demonstrar a integração entre IoT, processamento de dados, Machine Learning e IA generativa.

O modelo Random Forest foi treinado inicialmente com dados sintéticos. Portanto, suas classificações demonstram o funcionamento técnico da arquitetura, mas não devem ser interpretadas como previsões confiáveis de enchentes reais.

A API generativa está implementada e configurada para utilizar a OpenAI API. O serviço respondeu corretamente à verificação de saúde, mas a geração de mensagens ainda depende da resolução da limitação de cota ou faturamento identificada durante o teste.

Além disso, o protótipo utiliza sensores simulados no Wokwi e não representa uma instalação física de monitoramento ambiental.

Para uma utilização real, será necessário validar os sensores em campo, obter dados históricos confiáveis, avaliar o desempenho do modelo, verificar as condições de comunicação e estabelecer procedimentos de segurança e integração com os órgãos oficiais.

O AlertaCidadão não substitui os sistemas oficiais de alerta, as orientações da Defesa Civil ou as decisões das autoridades responsáveis. Seu objetivo é demonstrar como a tecnologia pode contribuir para o monitoramento ambiental e a comunicação preventiva.